Octobre 2026

Étude de cas Cyclistic

Comment les membres et les cyclistes occasionnels utilisent-ils les vélos différemment ?



Adji DIOR GUEYE

DANS LE CADRE DE LA CERTIFICATION GOOGLE DATA ANALYST

1. Énoncé de la tâche métier

Cyclistic est une entreprise de vélos en libre-service basée à Chicago (entreprise fictive de l'étude de cas). La directrice marketing, Lily Moreno, estime que la croissance future dépend du nombre d'abonnements annuels, plus rentables que les passes ponctuels.

Tâche métier : comprendre en quoi les membres (abonnement annuel) et les occasionnels (passe unique ou journée) utilisent les vélos différemment, afin d'orienter une stratégie marketing visant à convertir des occasionnels en membres.

Parties prenantes : Lily Moreno (directrice marketing), l'équipe d'analyse marketing, l'équipe de direction qui approuve les recommandations.

Périmètre : cette analyse traite la première des trois questions de l'étude de cas. Les questions sur les motivations d'achat et sur les médias numériques sont assignées à d'autres analystes.

2. Sources de données

Élément	Description
Source	Données publiques de trajets Divvy, fournies par Motivate International Inc. sous licence, présentées comme données Cyclistic dans l'étude de cas.
Période	12 mois : octobre 2025 à septembre 2026 (12 fichiers CSV mensuels).
Structure	Un trajet par ligne, 13 colonnes : identifiant, type de vélo, dates et heures de début et de fin, noms et identifiants des stations, coordonnées, type d'usager (member ou casual).
Volume	6 171 785 lignes brutes.
Confidentialité	Aucune donnée personnelle. Il est donc impossible de relier un trajet à une personne, de savoir si un occasionnel habite la zone, ou s'il a acheté plusieurs passes.
Limites	Le motif du trajet n'est pas enregistré. Une seule année de données. Environ 28 % des trajets en vélo électrique n'ont pas de station de départ.

3. Outils

- **Google BigQuery (SQL)** : volume de plus de 6 millions de lignes, trop lourd pour un tableur.
- **Python** : un petit script pour découper en deux les fichiers de plus de 100 Mo (limite de téléversement local de BigQuery). Concerne les mois 202510 et 202605 à 202609.
- **Power BI Desktop** : visualisations à partir de petites tables de synthèse.

4. Documentation du nettoyage

4.1 Chargement et assemblage

- 12 fichiers chargés dans BigQuery, soit 18 tables (6 fichiers découpés en deux parties).
- Vérification du schéma : aucune anomalie de type (started_at et ended_at en TIMESTAMP, coordonnées en FLOAT64).
- Assemblage en une table brute **trips_all** (6 171 785 lignes), avec deux colonnes calculées : **ride_length_min** (durée en minutes) et **day_of_week** (1 = dimanche, 7 = samedi).

4.2 Étapes de nettoyage

Étape	Règle	Lignes retirées	Lignes restantes
Table brute	trips_all	-	6 171 785
Doublons	Suppression des lignes entièrement identiques (SELECT DISTINCT)	35	6 171 750
Durées invalides	Durée négative ou nulle, ou dates manquantes	2 002	6 169 748 (trips_clean)
Faux départs	Trajets de moins de 1 minute	157 219	-
Durées extrêmes	Trajets de plus de 24 heures (1 440 min)	5 317	6 007 212 (analysis_trips)

Au total, **164 573 lignes (2,7 %)** ont été retirées. Table d'analyse finale : **analysis_trips, 6 007 212 trajets**, durée comprise entre 1 et 1 440 minutes.

4.3 Contrôles de cohérence

- member_casual ne contient que « member » et « casual » ; rideable_type que « classic_bike » et « electric_bike ».
- Stations de départ manquantes : uniquement sur les vélos électriques (27,6 % chez les occasionnels, 28,9 % chez les membres). Lignes conservées, car elles ne gênent ni la durée, ni le jour, ni l'heure.
- Coordonnées de fin manquantes : 308 lignes, conservées.

4.4 Décisions d'analyste

- Les seuils de 1 minute et de 24 heures sont un choix d'analyste, pas une règle. Ils retirent environ 2,6 % des trajets valides. Les trajets de 1 à 2 minutes (environ 135 000) ont été conservés, car ils peuvent être de vrais déplacements courts.
- La table mensuelle de synthèse exclut 58 trajets de septembre 2025 (25 occasionnels, 33 membres), présents dans le fichier d'octobre. Hypothèse non vérifiée : ils ont commencé fin septembre et ont été rattachés au fichier suivant.
- Les heures sont lues telles quelles, sans conversion de fuseau. Déduction non vérifiée : les pics à 8 h et 17 h chez les membres suggèrent que les heures sont déjà en heure locale de Chicago.
- Les 35 doublons sont identifiés par calcul : le nombre de lignes distinctes (6 171 750) est égal au nombre d'identifiants uniques. Un contrôle direct des paires n'a pas été réalisé.
- La médiane est calculée avec APPROX_QUANTILES, donc approximative.

5. Résumé de l'analyse

5.1 Tables de synthèse créées

Table	Contenu	Question
summary_by_day	Trajets et durée moyenne par jour et type d'usager	Quels jours ?
summary_by_hour	Trajets par heure de départ et type d'usager	À quelle heure ?
summary_by_month	Trajets et durée moyenne par mois et type d'usager	Quelle saison ?
summary_top_stations	10 stations de départ les plus utilisées par les occasionnels	Où ?

5.2 Chiffres clés

Indicateur	Occasionnels	Membres
Nombre de trajets	2 110 329 (35,1 %)	3 896 883 (64,9 %)
Durée moyenne	18,2 min	12,2 min
Durée médiane	11,1 min	8,7 min
Part des trajets le week-end	37 %	23 %
Part des trajets 7 h-8 h	6,0 %	12,8 %
Part des trajets 16 h-18 h	26,3 %	28,7 %
Part des trajets en été (juin-août)	46,4 %	37,4 %
Part des trajets en hiver (déc.-févr.)	4,3 %	9,7 %
Part de vélos électriques	74,2 %	68,3 %
Mois de pic	Juillet 2026 (345 551)	Août 2026 (511 009)
Mois le plus faible	Janvier 2026 (23 878)	Décembre 2025 (109 371)

Lecture. Les membres font presque deux fois plus de trajets, plus courts et réguliers, avec deux pics en semaine (8 h et 17 h). Les occasionnels roulent plus longtemps, davantage le week-end et l'après-midi, très concentrés sur la belle saison. Leurs stations de départ sont des sites touristiques du bord du lac : Navy Pier (49 559 trajets), DuSable Lake Shore Dr & Monroe St (28 566), Michigan Ave & Oak St (20 660), Millennium Park, Shedd Aquarium. Durée moyenne depuis ces stations : 25 à 33 minutes.

Prudence. Ces résultats décrivent des comportements, pas leurs causes. « Les membres font du domicile-travail » et « les occasionnels roulent pour leurs loisirs » sont des hypothèses cohérentes avec les données, non des preuves.

6. Visualisations

Quatre graphiques ont été réalisés dans Power BI Desktop, un par page, avec la même convention de couleurs (bleu clair : occasionnels, bleu foncé : membres) :

1. Nombre de trajets par jour de la semaine (histogramme groupé).
2. Nombre de trajets par heure de départ (courbes).
3. Nombre de trajets par mois (courbes).
4. Top 10 des stations de départ des occasionnels (barres horizontales).

[Insérer ici les captures d'écran des 4 graphiques.]

7. Recommandations

Recommandation 1 : proposer une offre de loisir centrée sur le week-end et l'après-midi

Constat. Le week-end représente 37 % des trajets des occasionnels (23 % chez les membres) ; avec le vendredi, 53 %. Leur pic est le samedi (447 265 trajets). Ils n'ont pas de pic matinal.

Action. Présenter l'abonnement comme une formule de balade et de sortie, plutôt que de trajet domicile-travail. Tester une offre d'essai ou liée au week-end.

Limite. Les données montrent quand ils roulent, pas pourquoi. Les tarifs sont à définir avec l'équipe finance.

Recommandation 2 : caler la campagne sur la saison

Constat. 46 % des trajets des occasionnels ont lieu de juin à août, 77 % d'avril à septembre. Janvier : 23 878 trajets ; juillet : 345 551.

Action. Lancer la campagne en mars ou avril, la maintenir jusqu'en septembre, puis un rappel en octobre. Peu de budget en hiver.

Limite. Une seule année de données : la stabilité de ce rythme est à confirmer.

Recommandation 3 : aller chercher les occasionnels là où ils roulent

Constat. Leurs stations principales sont touristiques et situées au bord du lac ; Navy Pier compte 1,7 fois plus de trajets que la deuxième.

Action. Affichages et QR codes d'inscription dans ces stations, complétés par de la publicité numérique géolocalisée, surtout le week-end d'avril à septembre.

Limite. Le classement exclut les trajets sans station de départ (environ 28 % des vélos électriques). Les 10 stations ne représentent que 11,7 % des trajets avec station connue.

8. Prochaines étapes

- Valider les hypothèses par un test auprès d'un échantillon d'occasionnels ou une enquête (question 2 de l'étude de cas).
- Ajouter des années de données pour confirmer la saisonnalité.
- Analyser les trajets en boucle (même station de départ et d'arrivée) pour mieux caractériser l'usage de loisir.
- Approfondir les canaux numériques (question 3 de l'étude de cas).